Simplest Vulkan Tutorial

天狗(Tengu712)

はじめに

コンセプト

網羅率を代償に、正しさを持って、簡単に速習すること。

他のチュートリアルでは軽視されがちな「理論」の部分に重点を置く。
読みやすく、わかりやすく、試しやすい、を意識している。

当スライドを見てもプログラムは組めない。
当スライドを見て、プログラムを俯瞰できるようにしてほしい。

想定の対象者層

次の程度のリテラシーは最低限欲しい：

- 行列の積が分かる
- コンピュータアーキテクチャが少し分かる

サンプルコード

本スライドには一切掲載しない。適宜以下のリンクを参照してほしい。
https://github.com/Tengu712/Vulkan-Tutorial

尚、**独特**なコーディング規則について、以下のよう：

- 列数に上限なし
- ifの分岐後命令が一つなら中括弧なし
- ifの分岐後命令が一つかつbreak、continue、returnなら改行
- 構造体の実体は初期化子で初期化
- 初期化子内は余程短くない限り改行
- 必要以上に関数・モジュール分割しない

参考文献

どのくらい参考したかはともかく、ぼくがVulkanを勉強する上で参考にした公式文献を除く文献(敬称略)：

- すらりん『Vulkan Programming Vol.1』
- Fadis『3Dグラフィクス API Vulkanを出来るだけやさしく解説する本』
- きてらい「やっていくVulkan入門」
- Alexander Overvoorde「VulkanTutorial」
- vblanco20-1「VulkanGuide」

RenderDoc

グラフィックプログラミングをしていると、
「コンパイルエラーもランタイムエラーもないが映らない」
なんてことがしょっちゅうある。

RenderDocを使うと以下を確認できたりするため、利用すべき：

- カラーバッファやデプスバッファ
- 各ステートの設定
- 各シェーダの入力と出力
- デプステストの結果

https://renderdoc.org/

Vulkan概要

Vulkanとは

グラフィックスAPIの一種。

OpenGLの後継。従来のAPIより低水準で自由。

グラフィックスAPIとは

主に**レンダリング**を目的とした、GPUを扱うための**API**。

「なぜAPIを介すのか？」
GPUのアーキテクチャは非公開であることが多く、アセンブリを書くのが現実的でないから。

「なぜGPUを使うのか？」
現状の並列計算力を比較してCPUよりGPUの方がレンダリング処理に強いから

レンダリングとは

画面に図形を描画すること。手法は色々考えられる。

主要グラフィックスAPIでは、一つの対象に対してパイプライン処理を行う。
レンダリングパイプラインと言う。

レンダリングパイプライン

描画対象を処理する工程。多くは大雑把に以下のよう：

1. インプットアセンブラ
2. ヴァーテックスシェーダ
3. ビューポート変換
4. ラスタライゼーション
5. フラグメントシェーダ
6. 合成

Vulkanのレンダリングパイプライン

概ね右の通り。

参考元：

Khronos Group,

Vulkan 1.1 Quick Reference

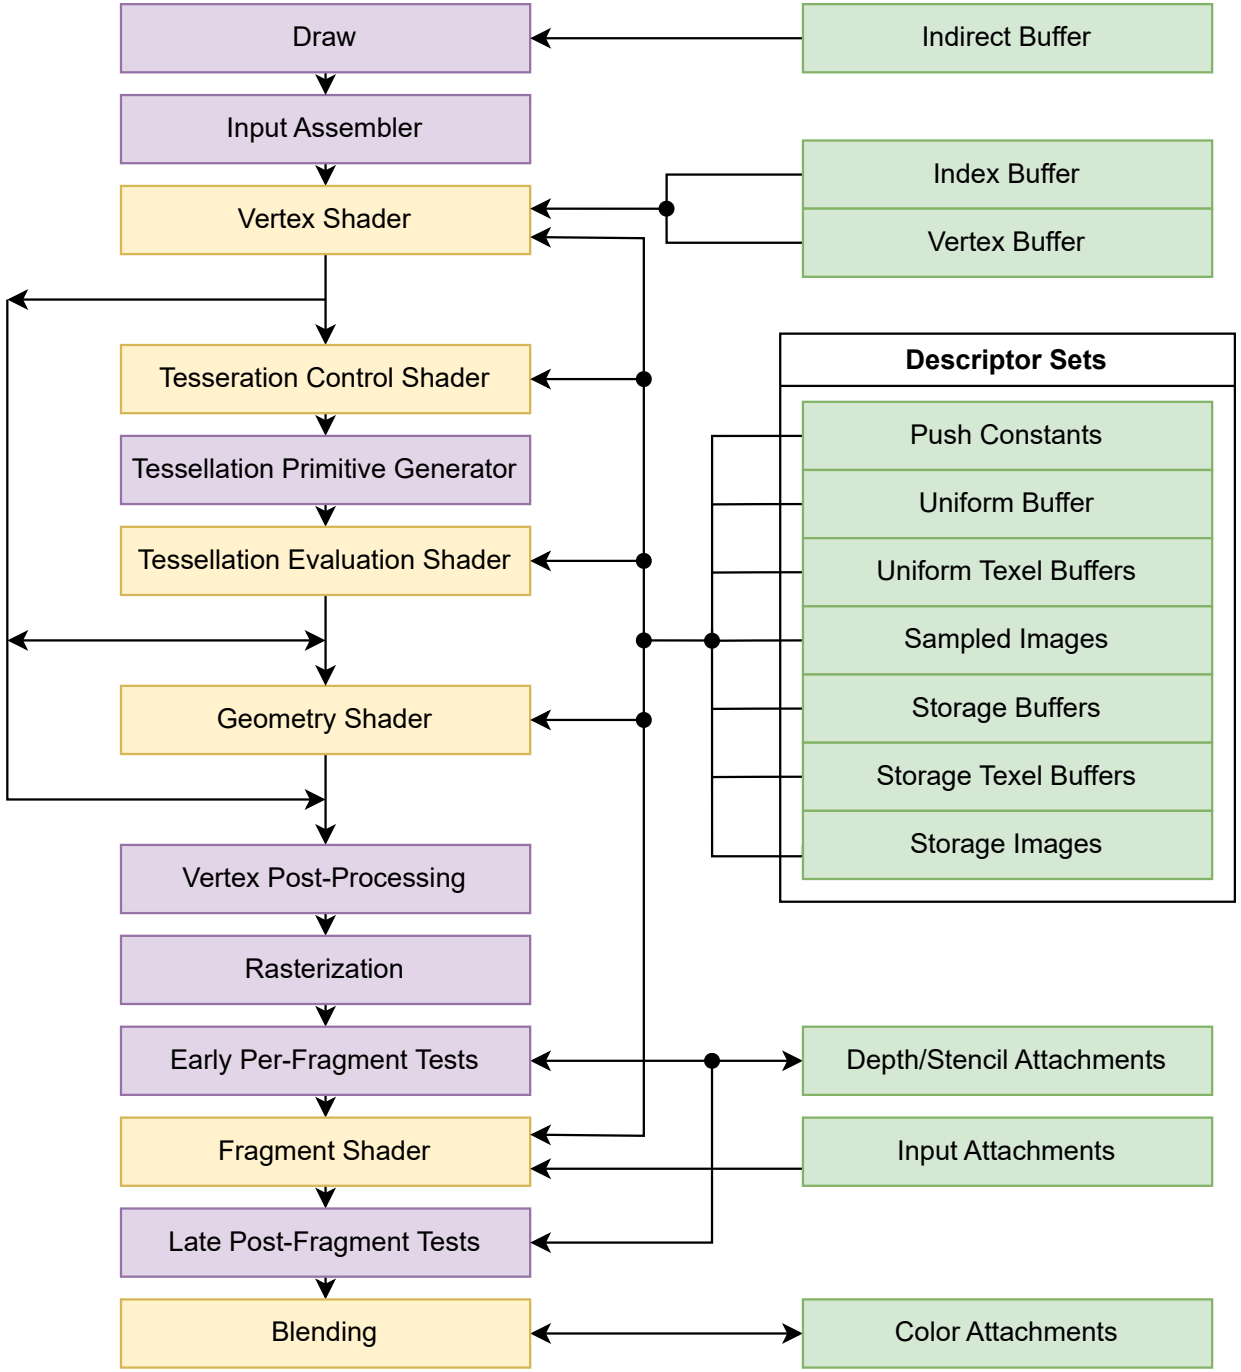

今回扱う部分

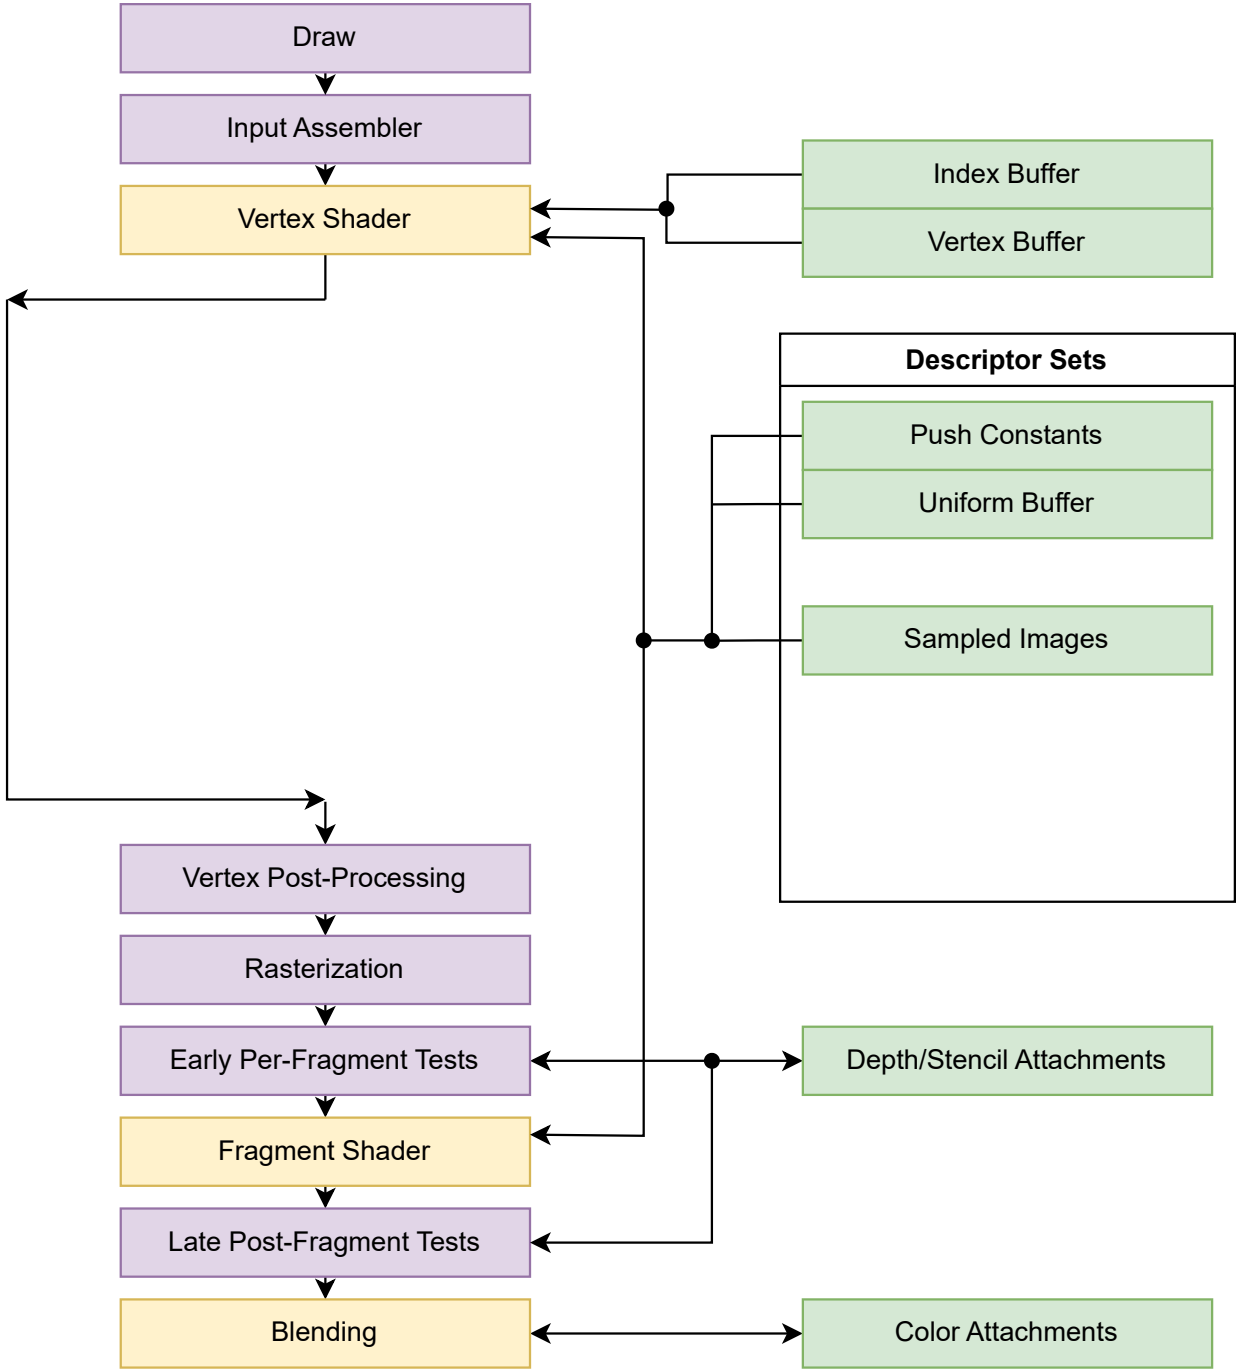
Draw
Input Assembler
Vertex Shader
Index Buffer
Vertex Buffer
Descriptor Sets
Push Constants
Uniform Buffer
Sampled Images
Vertex Post-Processing
Rasterization
Early Per-Fragment Tests
Depth/Stencil Attachments
Fragment Shader
Late Post-Fragment Tests
Blending
Color Attachments

プログラマは何をすればいいか

Vulkanに詳細な設定を与えて、Vulkanを介してGPUに計算させる。

難しいアルゴリズムを考える必要は皆無。とにかく仕様と睨めっこ。

GPUを扱うために

GPUは遠隔リソース

普通GPUは、CPUと非同期に動作するデバイス。

またGPUは、PCI-Expressを介してメインメモリにアクセスできるが、
そのメモリ管理ユニットはCPUのものと異なる。

従って、**非同期処理が大前提**となる。

キューとコマンド

GPUに計算をさせるためには、GPUのコマンドキューにコマンドを流す。

Vulkanにおいては、コマンドバッファにコマンドを積んでから、コマンドバッファごとキューに提出する。
コレクションの`push_all`メソッドみたいな。

提出されるなり、GPUは非同期に計算を始める。

同期の取り方

CPU-GPU間

- フェンスを用いる。
  コマンドバッファをキューに提出する際、フェンスを指定できる。
  提出したコマンドがすべて処理されるまで`vkWaitForFences`関数でCPUを休止できる。
- `vkDeviceWaitIdle`関数を用いる。
  プロセスから提出されたすべてコマンドが処理されるまでCPUを休止できる。

GPU-GPU間

- セマフォを用いる。
  GPU-GPU間で同期を取るべき処理各所で指定する。

メモリの種類

メモリには少なくとも以下の二種類がある：

- メインメモリ(RAM)：CPUが扱うのに適したメモリ
- デバイスメモリ(VRAM)：GPUが扱うのに適した、CPUが扱えないメモリ

GPUからメインメモリ上のデータを扱うためには、
PCI-Expressを介すため、デバイスメモリ上のデータを扱うより遅い。

GPUしか扱わない・初期化後に更新しないデータは、デバイスメモリに格納するのが良い。

デバイスメモリ

CPUはデバイスメモリを直接扱えないため、
CPUからデバイスメモリ上にデータを格納する場合は、以下の手順を踏む：

1. デバイスメモリを確保する
2. メインメモリにステージングバッファを確保する
3. ステージングバッファにデータを格納する
4. コピーコマンドを用いて、
   GPUにステージングバッファのデータをデバイスメモリへコピーしてもらう

画面を一色にクリアする

描画の仕組み (不確定情報)

「フレームバッファ」とは、デバイスメモリ上に存在する描画表示領域。
`ディスプレイ幅xディスプレイ高xピクセルサイズ` のサイズの色情報配列。

ディスプレイのスキャンタイミングに合わせて「フレームバッファ」をディスプレイへ転送することで、ディスプレイに映像が表示される。

たぶん転送は、GPUによってCPUとは非同期的に行われる。

垂直同期 (不確定情報)

ディスプレイの走査線が右下から左上に戻るタイミング

＝　画面の更新が完了して次の更新が始まるまでのタイミング

に合わせること。

アプリが垂直同期を取らずにプレゼンテーションを行う

＝　ディスプレイへ転送中のフレームバッファに書き込みを行う

スワップチェーン (不確定情報)

Vulkanを用いて「フレームバッファ」に書き込むためには、
スワップチェーンを用いる。

1. ウィンドウのサーフェス(のサイズ等)に応じたスワップチェーンを作成する
2. スワップチェーンの扱えるイメージのイメージビューを作成する
3. レンダーパスを作成する
4. レンダーパスとスワップチェーンイメージビューとを関連させた、
   フレームバッファを作成する
5. フレームバッファを介してスワップチェーンイメージへレンダリングを行う
6. プレゼンテーションを行って「フレームバッファ」へ書き込む

レンダーパス

描画の全体の動きを制御するオブジェクト。

- どのアタッチメント(描画先イメージやデプスバッファ)を用いるか
- どの順番でどう描画するか

レンダリングパイプライン等の具体的な描画工程は示さない。

レンダーパスを開始するとき、アタッチメントをクリアできる。
カラーアタッチメントなら一色にクリアできる。

画面を一色にクリアする

準備：

1. サーフェス作成
2. サーフェスに応じたスワップチェーン作成
3. スワップチェーンイメージのイメージビュー作成
4. カラーアタッチメントを用いるレンダーパス作成
5. レンダーパスとスワップチェーンイメージビューを関連させた、
   フレームバッファ作成

画面を一色にクリアする

描画：

1. コマンドバッファ開始
2. レンダーパス開始
   このとき、アタッチメントの初期値(クリア色)を指定
3. レンダーパス終了
4. コマンドバッファ終了
5. コマンドバッファをキューに提出
6. プレゼンテーションコマンドをキューに追加
   垂直同期がオンならば、垂直同期を取ってバッファに書き込まれる
   書き込まれるまでスレッドが休止する

頂点入力

ポリゴンの作り方

三角形を繋ぎ合わせてモデル全体を作る。

そもそも三角形は三つの頂点を順に結んで作る。
結び方に種類があり、インプットアセンブラに設定する。主に以下：

- TRIANGLE_LIST
- TRIANGLE_STRIP
- TRIANGLE_FAN

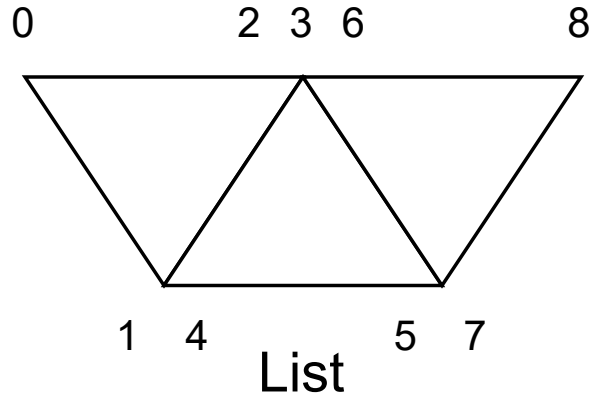

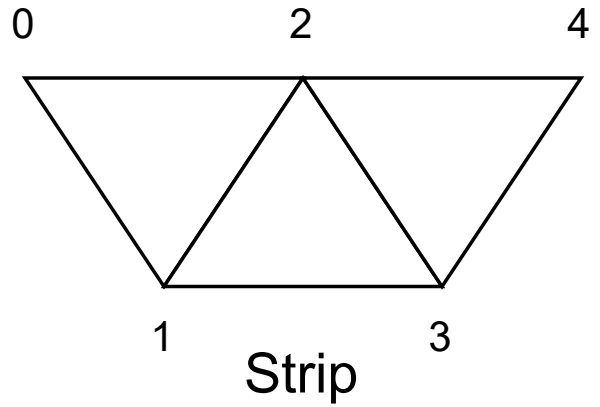

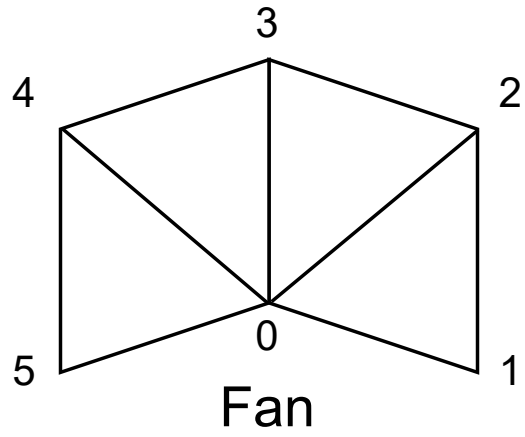

頂点バッファとインデックスバッファ

頂点情報を羅列した「頂点バッファ」と
頂点を結ぶ順番を羅列した「インデックスバッファ」を
インプットアセンブラに渡す。

頂点情報

一つの頂点は複数の情報を持ちうる。

- ローカル座標
- UV座標
- 法線ベクトル
- 頂点色
- 頂点ごとのパラメータ

頂点シェーダへの入力となるため、データ構造を頂点シェーダに教えておく。

頂点シェーダ

頂点シェーダ

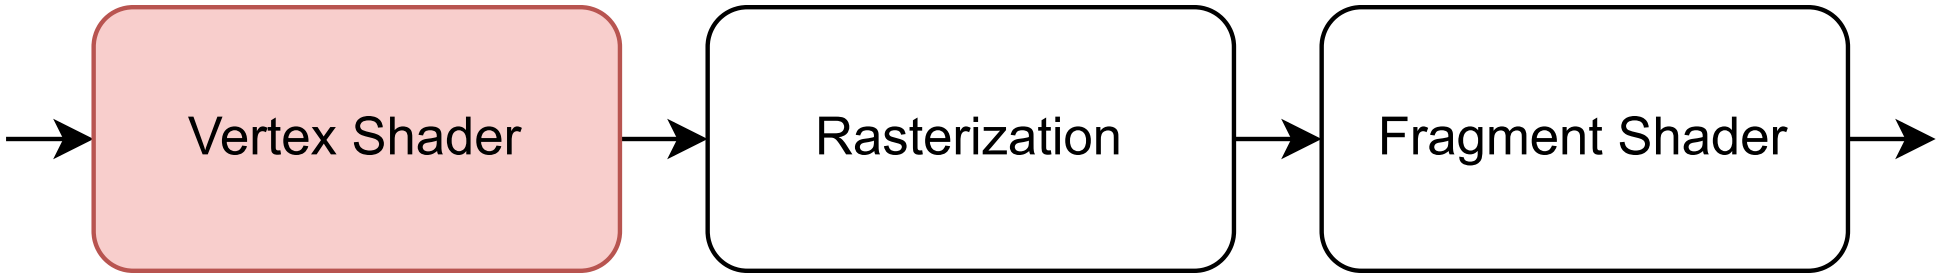

レンダリングパイプラインのステージの一つ。

主に頂点座標変換を行う。

プログラマブル。GLSLやHLSL等で記述する。
Vulkanでは、さらにSPIR-Vにコンパイルしたものを用いる。

頂点座標変換

Vulkanの扱う座標系をクリッピング座標系という。
描画対象となる範囲は、x, yが$[-1, 1]$、zが$[0, 1]$。

一般的に次の順で座標系を変えていく：

1. ローカル座標系：モデル内の座標 (入力)
2. ワールド座標系：3D空間の絶対座標
3. ビュー座標系：カメラから見た座標
4. (視錘台内の座標系)：正規化される前の座標 (出力)

最終的に、口述するビューポート変換によってクリッピング座標系へ変換される。

ローカル座標

ローカル座標および各変換後の座標を以下とする：

$$\begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}$$

これに左から行列をかけることで変換していく。
いわゆるアフィン変換。

四行目の値は、計算上特に平行移動で役に立ち、最終的には縮小率を表す。

ワールド座標変換

次の順で行うのが良い (つまり次の順で行列を右から並べる) :

1. 拡大縮小
2. 回転
3. 平行移動

ワールド座標変換 (拡大縮小)

$$\begin{bmatrix} s_x & 0 & 0 & 0 \\ 0 & s_y & 0 & 0 \\ 0 & 0 & s_z & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix} = \begin{bmatrix} s_x x \\ s_y y \\ s_z z \\ 1 \end{bmatrix}$$

ワールド座標変換 (x軸周りの回転)

回転角をθラジアンとして：

$$\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & \cos\theta & \sin\theta & 0 \\ 0 & -\sin\theta & \cos\theta & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix} = \begin{bmatrix} x \\ \cos(\theta)y + \sin(\theta)z \\ -\sin(\theta)y + \cos(\theta)z \\ 1 \end{bmatrix}$$

ワールド座標変換 (Y軸周りの回転)

回転角をθラジアンとして：

$$\begin{bmatrix} \cos\theta & 0 & -\sin\theta & 0 \\ 0 & 1 & 0 & 0 \\ \sin\theta & 0 & \cos\theta & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix} = \begin{bmatrix} \cos(\theta)x - \sin(\theta)z \\ y \\ \sin(\theta)x + \cos(\theta)z \\ 1 \end{bmatrix}$$

ワールド座標変換 (Z軸周りの回転)

回転角をθラジアンとして：

$$\begin{bmatrix} \cos\theta & \sin\theta & 0 & 0 \\ -\sin\theta & \cos\theta & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix} = \begin{bmatrix} \cos(\theta)x + \sin(\theta)y \\ -\sin(\theta)x + \cos(\theta)y \\ z \\ 1 \end{bmatrix}$$

ワールド座標変換 (平行移動)

$$\begin{bmatrix} 1 & 0 & 0 & t_x \\ 0 & 1 & 0 & t_y \\ 0 & 0 & 1 & t_z \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix} = \begin{bmatrix} x + t_x \\ y + t_y \\ z + t_z \\ 1 \end{bmatrix}$$

ビュー座標変換

$$V_{trs} = (\text{平行移動行列})^{-1}$$
$$V_{rtz} = (Z\text{軸周りの回転行列})^{-1}$$
$$V_{rty} = (Y\text{軸周りの回転行列})^{-1}$$
$$V_{rtx} = (X\text{軸周りの回転行列})^{-1}$$

として、ビュー座標変換行列は、

$$V_{trs}V_{rtz}V_{rty}V_{rtx}$$

射影変換 (平行投影)

遠近感をつけない。
wが1になるので、実質的にクリッピング座標系へ変換する。

幅を$width$、高さを$height$、深さを$depth$とすると、

$$\begin{bmatrix} 1/width & 0 & 0 & 0 \\ 0 & 1/height & 0 & 0 \\ 0 & 0 & 1/depth & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix} = \begin{bmatrix} x/width \\ y/height \\ z/depth \\ 1 \end{bmatrix}$$

射影変換 (透視投影)

遠近感をつける。

wはビュー座標系におけるzとなる。

視野角の半分をθ、アスペクト比を$aspect$、前近面のz座標を$near$、遠方面のz座標をfarとすると、

$$\begin{bmatrix} 1/\tan\theta & 0 & 0 & 0 \\ 0 & aspect/\tan\theta & 0 & 0 \\ 0 & 0 & \frac{far}{far-near} & \frac{-far \cdot near}{far-near} \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix} = \begin{bmatrix} x/\tan\theta \\ y \cdot aspect/\tan\theta \\ \frac{(z-near)far}{far-near} \\ z \end{bmatrix}$$

注意点

少なくともVulkan+GLSLでは、**列優先**なので、転置した状態でシェーダに渡す。

```
// 普通の処理系
float mat4x4[][] = {
  { a11, a12, a13, a14 },
  { a21, a22, a23, a24 },
  { a31, a32, a33, a34 },
  { a41, a42, a43, a44 },
};
// シェーダに渡したとき
{ a11, a21, a31, a41, a12, a22, a32, ... }
```

頂点シェーダ ~ フラグメントシェーダ

役割

各頂点の計算から、各ピクセルの計算への移行。

頂点シェーダからの出力の内、`stat`でない値の補完。

ビューポート変換

頂点シェーダの出力をクリッピング座標系に変換する。

$$\frac{1}{w}\begin{bmatrix} x \\ y \\ z \\ w \end{bmatrix} = \begin{bmatrix} x/w \\ y/w \\ z/w \\ 1 \end{bmatrix} = \begin{bmatrix} p_x \\ p_y \\ p_z \\ 1 \end{bmatrix}$$

p_x, p_yがビューポート上の座標、p_zが深度値となる。

カリング

裏面を向いているポリゴンを削除する。
フラグメントシェーダの計算量を抑えるために行われる。

表裏判定は、頂点の結ぶ向きが時計回りか反時計回りかで行う。

OpenGL系では慣習的に反時計回りを表とする。

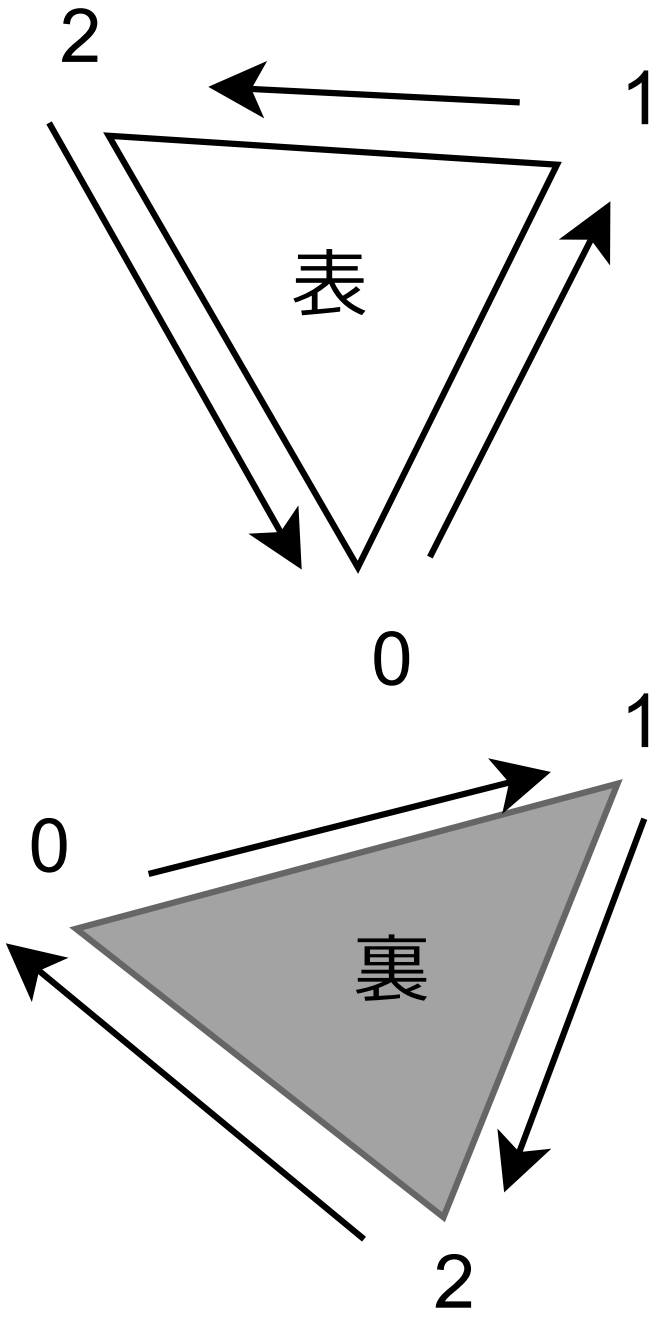

ラスタライズとマルチサンプル

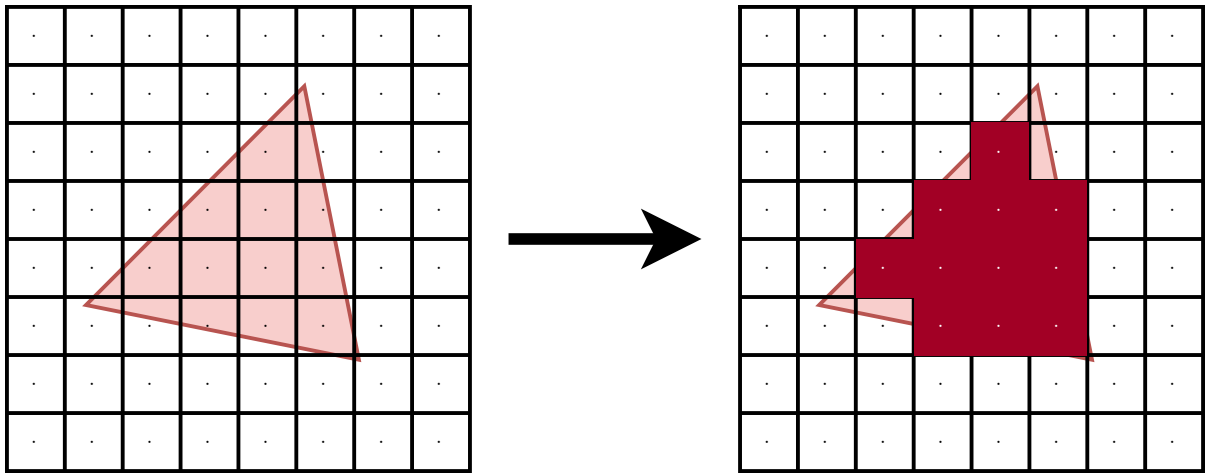

各ピクセルに対して図形の内外判定を行う。

サンプルの数を増やしcoverage値を算出することで滑らかに描画することを、
マルチサンプルという。

デプステスト

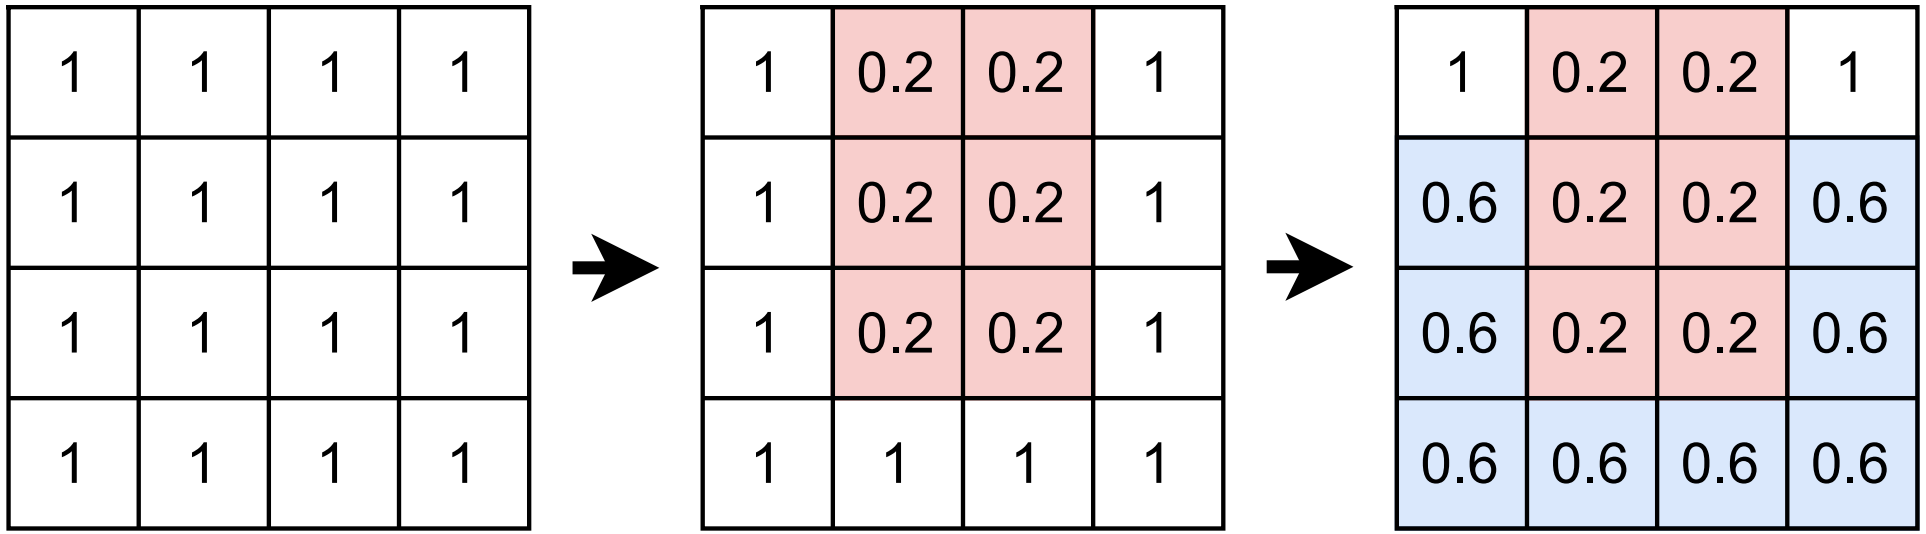

デプスバッファ上の値と比較して、ピクセルを描画するか否か決める。

透視投影変換行列の罠

前近面のz座標を0とすると、行列は簡単になるが、**深度値が必ず1になる**。

$$\begin{bmatrix} 1/\tan\theta & 0 & 0 & 0 \\ 0 & aspect/\tan\theta & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix} = \begin{bmatrix} x/\tan\theta \\ y \cdot aspect/\tan\theta \\ z \\ z \end{bmatrix}$$

$$\frac{1}{z} \begin{bmatrix} x/\tan\theta \\ y \cdot aspect/\tan\theta \\ z \\ z \end{bmatrix} = \begin{bmatrix} x/z\tan\theta \\ y \cdot aspect/z\tan\theta \\ 1 \\ 1 \end{bmatrix}$$

フラグメントシェーダと合成

色の決定

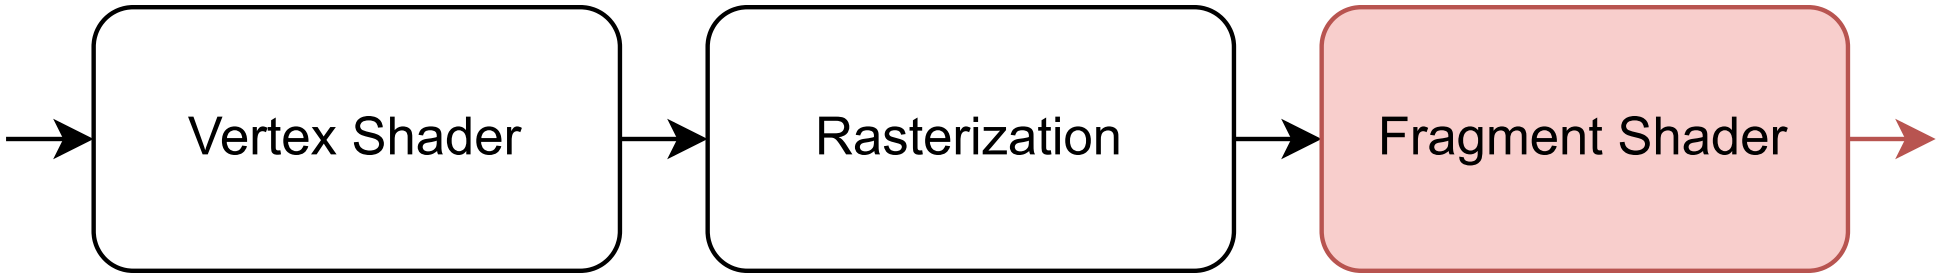

フラグメントシェーダの出力がピクセルの色となる。

テクスチャマッピング

UV座標をもとに、サンプラー(画像テクスチャ)から色を持ってくる。

UV座標や色をいじることで、画像加工ができる：

- 色を$1-(1-src)(1-dst)$とする -> スクリーン
- UV座標を一定区間でfloorなりceilなりする -> モザイク
- テクスチャ上の周辺の色と混成する -> ぼかし
- 等々

文字描画

普通、グラフィックスAPIには文字描画の機能がない。

次の二つの方法が考えられ、計算量と実装の楽さから一般的には上を用いる：

- あらかじめビットマップテクスチャにしておく方法
- ピクセルシェーダ内で初めてグリフの内外判定を行う方法

ブレンディング

スワップチェーンイメージに結果を合成する。

色も透過率も次のように設定すると、アルファブレンドされる：

- 描画元：src
- 描画先：$dst - src$

ディスクリプタセット

シェーダ内で扱う大きなデータ

次のようにしてデータを切り替え**られない**：

1. コマンドバッファ開始
2. レンダーパス開始
3. **データ1をセット**するコマンドを積む
4. **モデル1を描画**するコマンドを積む
5. **データ2をセット**するコマンドを積む
6. **モデル2を描画**するコマンドを積む
7. レンダーパス終了
8. コマンドバッファ終了
9. コマンドバッファをキューに提出

ディスクリプタセット

予め、バインディング(データスロットと思っていい)の数・種類を把握しておく。

また描画前に予め、「どのバインディングにどのデータを当てるか」という組合わせを必要分すべてメモリ上に配置しておき、その組合わせを教える。

1. **組合わせ1をセット**するコマンドを積む
2. **モデル1を描画**するコマンドを積む
3. **組合わせ2をセット**するコマンドを積む
4. **モデル2を描画**するコマンドを積む

この組合わせをディスクリプタセットという。(セットは集合の意味のset)

ディスクリプタセットの総数

例えば、l種類のカメラ、m種類の光源、n種類の画像を使う場合、
必要なディスクリプタセットの数は、

$$l \cdot m \cdot n\text{個}$$

になる。